Московский государственный технический университет им. Н.Э. Баумана Факультет «Информатика и системы управления» Кафедра «Системы обработки информации и управления»



Отчет

по лабораторной работе № 6 по курсу «Технологии машинного обучения»

«Ансамбли моделей машинного обучения.»

ИСПО	ОЛНИТЕЛЬ:
_	ов Владислав чппа ИУ5-64Б
""	_2020 г.
	ДАВАТЕЛЬ: Гапанюк Ю.Е.
"_"	2020 r.

Цель лабораторной работы

Изучение ансамблей моделей машинного обучения

Задание

- 1. Выберите набор данных (датасет) для решения задачи классификации или регресии.
- 2. В случае необходимости проведите удаление или заполнение пропусков и кодирование категориальных признаков.
- 3. С использованием метода train_test_split разделите выборку на обучающую и тестовую.
- 4. Обучите две ансамблевые модели. Оцените качество моделей с помощью одной из подходящих для задачи метрик. Сравните качество полученных моделей.

Ход выполнения лабораторной работы

In [40]:

```
import pandas as pd
import seaborn as sns
import numpy as np
import matplotlib.pyplot as plt
from sklearn.preprocessing import MinMaxScaler, LabelEncoder
from sklearn.model selection import train test split
from sklearn.metrics import fl_score, precision_score, recall_score, accuracy_score
from sklearn.ensemble import RandomForestClassifier
from sklearn.ensemble import GradientBoostingClassifier
%matplotlib inline
# Устанавливаем тип графиков
sns.set(style="ticks")
# Для лучшего качествоа графиков
from IPython.display import set matplotlib formats
set_matplotlib_formats("retina")
# Устанавливаем ширину экрана для отчета
pd.set option("display.width", 70)
# Загружаем данные
data = pd.read csv('../data/hotel bookings.csv')
data.head()
```

Out[40]:

	hotel	is_canceled	lead_time	arrival_date_year	arrival_date_month	arrival_date_week_numbe
0	Resort Hotel	0	342	2015	July	2'
1	Resort Hotel	0	737	2015	July	2.
2	Resort Hotel	0	7	2015	July	2.
3	Resort Hotel	0	13	2015	July	2.
4	Resort Hotel	0	14	2015	July	2.

5 rows × 32 columns

In [41]:

```
data = data.dropna()
data.isnull().sum()
```

Out[41]:

hotel	0
is_canceled	0
lead_time	0
arrival_date_year	0
arrival_date_month	0
arrival_date_week_number	0
arrival_date_day_of_month	0
stays_in_weekend_nights	0
stays_in_week_nights	0
adults	0
children	0
babies	0
meal	0
country	0
market_segment	0
distribution_channel	0
is_repeated_guest	0
previous_cancellations	0
<pre>previous_bookings_not_canceled</pre>	0
reserved_room_type	0
assigned_room_type	0
booking_changes	0
deposit_type	0
agent	0
company	0
days_in_waiting_list	0
customer_type	0
adr	0
required_car_parking_spaces	0
total_of_special_requests	0
reservation_status	0
reservation_status_date	0
dtype: int64	

In [42]:

data.isna().sum()

Out[42]:

hotel	0
is canceled	0
lead time	0
arrival date year	0
arrival date month	0
arrival date week number	0
arrival_date_day_of_month	0
stays_in_weekend_nights	0
stays in week nights	0
adults	0
children	0
babies	0
meal	0
country	0
market segment	0
distribution channel	0
is repeated guest	0
previous cancellations	0
previous bookings not canceled	0
reserved room type	0
assigned room type	0
booking changes	0
deposit type	0
agent	0
company	0
days in waiting list	0
customer type	0
adr	0
required_car_parking_spaces	0
total_of_special_requests	0
reservation status	0
reservation status date	0
dtype: int64	·

In [43]:

data.shape

Out[43]:

(217, 32)

In [44]:

data.columns

Out[44]:

In [45]:

data.dtypes

Out[45]:

- h +
object
int64
int64
int64
object
int64
float64
int64
object
object
object
object
int64
int64
int64
object
object
int64
object
float64
float64
int64
object
float64
int64
int64
object
object
-

Но сначала сделаем, кодирование категориальных признаков.

```
In [46]:
le1 = LabelEncoder()
data['hotel'] = le1.fit_transform(data['hotel']);
In [47]:
le2 = LabelEncoder()
data['arrival_date_month'] = le2.fit_transform(data['arrival_date_month']);
In [48]:
le3 = LabelEncoder()
data['meal'] = le3.fit_transform(data['meal']);
In [49]:
le4 = LabelEncoder()
data['country'] = le4.fit_transform(data['country']);
In [50]:
le5 = LabelEncoder()
data['market_segment'] = le5.fit_transform(data['market_segment']);
In [51]:
le6 = LabelEncoder()
data['distribution_channel'] = le6.fit_transform(data['distribution_channel']);
In [52]:
le7 = LabelEncoder()
data['reserved_room_type'] = le7.fit_transform(data['reserved_room_type']);
In [53]:
le8 = LabelEncoder()
data['deposit_type'] = le8.fit_transform(data['deposit_type']);
In [54]:
le9 = LabelEncoder()
data['customer_type'] = le9.fit_transform(data['customer_type']);
In [55]:
le9 = LabelEncoder()
data['reservation_status'] = le9.fit_transform(data['reservation_status']);
In [56]:
le10 = LabelEncoder()
data['reservation_status_date'] = le10.fit_transform(data['reservation_status_date']
```

```
In [58]:
```

```
# Убедимся, что целевой признак
# для задачи бинарной классификации содержит только 0 и 1
data['is canceled'].unique()
Out[58]:
array([0, 1])
In [59]:
# Оценим дисбаланс классов для Оссирапсу
fig, ax = plt.subplots(figsize=(4,4))
plt.hist(data['is canceled'])
plt.show()
 200
 175
 150
 125
 100
 75
  50
 25
  0
          0.2
                0.4
                     0.6
                           0.8
     0.0
In [60]:
data['is_canceled'].value_counts()
Out[60]:
0
     200
      17
1
Name: is_canceled, dtype: int64
In [61]:
# посчитаем дисбаланс классов
total = data.shape[0]
```

.format(round(class_0 / total, 2)*100, round(class_1 / total, 2)*100))

Класс 0 составляет 8.0%, а класс 1 составляет 92.0%.

class_1, class_0 = data['is_canceled'].value_counts()
print('Класс 0 составляет {}%, а класс 1 составляет {}%.'

Дисбаланса классов практически нет

Проведем масштабирование данных

```
In [85]:
```

```
ous_bookings_not_canceled', 'required_car_parking_spaces', 'country', 'meal', 'market
```

In [86]:

```
sc1 = MinMaxScaler()
sc1_data = sc1.fit_transform(data[scale_cols])
```

In [87]:

```
# Добавим масштабированные данные в набор данных

for i in range(len(scale_cols)):
    col = scale_cols[i]
    new_col_name = col + '_scaled'
    data[new_col_name] = sc1_data[:,i]
```

In [88]:

```
data.head()
```

Out[88]:

	hotel	is_canceled	lead_time	arrival_date_year	arrival_date_month	arrival_date_week_numb
2392	1	0	6	2015	10	
2697	1	0	24	2015	10	4
2867	1	0	24	2015	9	
2877	1	0	24	2015	9	4
2878	1	0	24	2015	9	

5 rows × 50 columns

```
In [89]:
corr cols 1 = scale cols + ['is canceled']
corr_cols_1
Out[89]:
['lead time',
 'arrival date year',
 'arrival date week number',
 'arrival date day of month',
 'stays in weekend nights',
 'stays in week nights',
 'adults',
 'children',
 'babies',
 'is repeated guest',
 'previous_cancellations',
 'previous bookings not canceled',
 'required car parking spaces',
 'country',
 'meal',
 'market segment',
 'reservation status',
 'hotel',
 'is canceled']
In [90]:
scale cols postfix = [x+' scaled' for x in scale cols]
corr cols 2 = scale cols postfix + ['is canceled']
corr cols 2
Out[90]:
['lead time scaled',
 'arrival_date_year_scaled',
 'arrival_date_week_number_scaled',
 'arrival date day of month scaled',
 'stays in weekend nights scaled',
 'stays in week nights scaled',
 'adults scaled',
 'children_scaled',
 'babies scaled',
 'is repeated guest scaled',
 'previous cancellations scaled',
 'previous bookings not canceled scaled',
 'required_car_parking_spaces_scaled',
 'country_scaled',
 'meal scaled',
 'market segment scaled',
 'reservation status scaled',
 'hotel scaled',
```

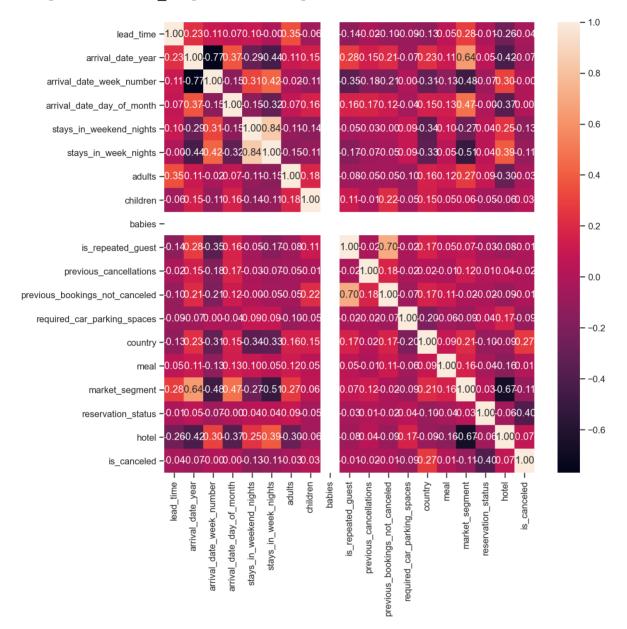
'is_canceled']

In [91]:

```
fig, ax = plt.subplots(figsize=(10,10))
sns.heatmap(data[corr_cols_1].corr(), annot=True, fmt='.2f')
```

Out[91]:

<matplotlib.axes. subplots.AxesSubplot at 0x125f4c510>

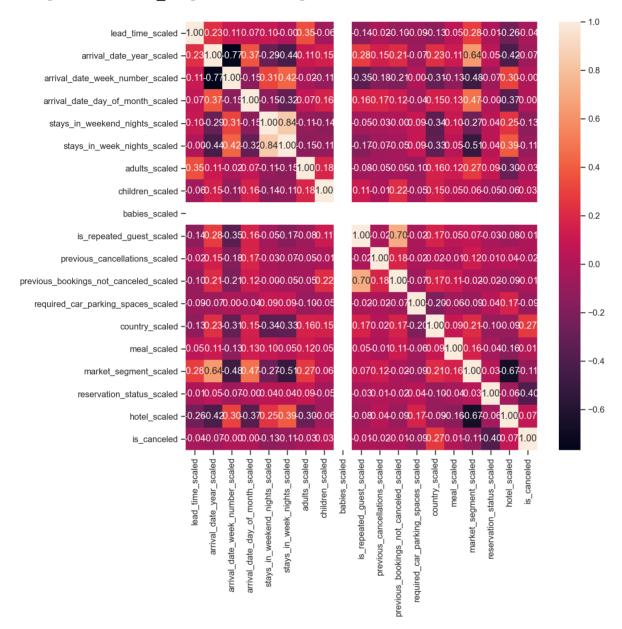


In [92]:

```
fig, ax = plt.subplots(figsize=(10,10))
sns.heatmap(data[corr_cols_2].corr(), annot=True, fmt='.2f')
```

Out[92]:

<matplotlib.axes. subplots.AxesSubplot at 0x12763f1d0>



На основе корреляционной матрицы можно сделать следующие выводы:

- * Корреляционные матрицы для исходных и масштабированных данных совпадают;
- * Оставим только 'country', 'meal', 'reservation_status', 'hotel', так как они имеют корреляцию с целевым признаком.

```
In [93]:
```

```
# Числовые колонки для масштабирования class_cols = ['country', 'meal', 'reservation_status', 'hotel']
```

In [94]:

```
X = data[class_cols]
y = data['is_canceled']
print(X, "\n")
print(y)
```

```
country meal
                         reservation status
                                                hotel
2392
              15
                                             1
                      0
                                                     1
                      0
2697
               1
                                             1
                                                     1
2867
               8
                      0
                                             1
                                                     1
2877
              15
                      0
                                             1
                                                     1
2878
              12
                                             1
                                                     1
             . . .
112499
               5
                      0
                                             1
                                                     0
113046
              12
                      0
                                             1
                                                     0
113082
              12
                                             1
                                                     0
113627
              10
                      0
                                             1
                                                     0
116451
              15
                                             1
[217 rows x 4 columns]
2392
           0
2697
           0
           0
2867
2877
           0
           0
2878
112499
           0
113046
           0
113082
           n
           0
113627
116451
           0
Name: is canceled, Length: 217, dtype: int64
```

Разделим выборку на обучающую и тестовую

In [95]:

y_train: (162,)
y_test: (55,)

```
# С использованием метода train_test_split разделим выборку на обучающую и тестовую
X_train, X_test, y_train, y_test = train_test_split(X, y, test_size=0.25, random_staprint("X_train:", X_train.shape)
print("X_test:", X_test.shape)
print("y_train:", y_train.shape)
print("y_test:", y_test.shape)

X_train: (162, 4)
X_test: (55, 4)
```

In [96]:

```
class MetricLogger:
    def init (self):
        self.df = pd.DataFrame(
            {'metric': pd.Series([], dtype='str'),
            'alg': pd.Series([], dtype='str'),
            'value': pd.Series([], dtype='float')})
    def add(self, metric, alg, value):
        Добавление значения
        # Удаление значения если оно уже было ранее добавлено
        self.df.drop(self.df[(self.df['metric']==metric)&(self.df['alg']==alg)].inde
        # Добавление нового значения
        temp = [{'metric':metric, 'alg':alg, 'value':value}]
        self.df = self.df.append(temp, ignore index=True)
    def get data for metric(self, metric, ascending=True):
        Формирование данных с фильтром по метрике
        temp data = self.df[self.df['metric']==metric]
        temp_data_2 = temp_data.sort_values(by='value', ascending=ascending)
        return temp data 2['alg'].values, temp data 2['value'].values
    def plot(self, str header, metric, ascending=True, figsize=(5, 5)):
        Вывод графика
        array labels, array metric = self.get data for metric(metric, ascending)
        fig, ax1 = plt.subplots(figsize=figsize)
        pos = np.arange(len(array_metric))
        rects = ax1.barh(pos, array metric,
                         align='center',
                         height=0.5,
                         tick label=array labels)
        ax1.set title(str header)
        for a,b in zip(pos, array_metric):
            plt.text(0.5, a-0.05, str(round(b,3)), color='white')
        plt.show()
```

In [97]:

```
# Сохранение метрик
metricLogger = MetricLogger()
```

In [98]:

```
def test model(model name, model, metricLogger):
   model.fit(X_train, y_train)
   y pred = model.predict(X test)
   accuracy = accuracy score(y test, y pred)
   f1 = f1_score(y_test, y_pred)
   precision = precision_score(y_test, y_pred)
   recall = recall_score(y_test, y_pred)
   metricLogger.add('precision', model name, precision)
   metricLogger.add('recall', model name, recall)
   metricLogger.add('f1', model_name, f1)
   metricLogger.add('accuracy', model_name, accuracy)
   print(model)
   print(model name)
   print("accuracy:", accuracy)
   print("f1_score:", f1)
   print("precision_score:", precision)
   print("recall:", recall)
```

Обучим модели

Будем использовать модели: случайный лес, градиентный бустинг

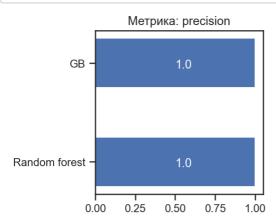
```
In [99]:
```

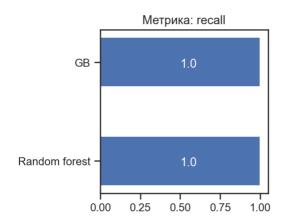
```
test model('Random forest', RandomForestClassifier(), metricLogger)
test model('GB', GradientBoostingClassifier(), metricLogger)
****************
RandomForestClassifier(bootstrap=True, ccp alpha=0.0, class weight=Non
                     criterion='gini', max depth=None, max features
='auto',
                     max leaf nodes=None, max samples=None,
                     min_impurity_decrease=0.0, min_impurity_split=N
one.
                     min samples leaf=1, min samples split=2,
                     min weight fraction leaf=0.0, n estimators=100,
                     n jobs=None, oob score=False, random state=Non
e,
                     verbose=0, warm start=False)
Random forest
accuracy: 1.0
f1 score: 1.0
precision score: 1.0
recall: 1.0
*****************
***************
GradientBoostingClassifier(ccp alpha=0.0, criterion='friedman mse', in
it=None,
                        learning_rate=0.1, loss='deviance', max_dep
th=3,
                        max features=None, max leaf nodes=None,
                        min impurity decrease=0.0, min impurity spl
it=None,
                        min samples leaf=1, min samples split=2,
                        min weight fraction leaf=0.0, n estimators=
100,
                        n iter no change=None, presort='deprecate
d',
                        random state=None, subsample=1.0, tol=0.000
1,
                        validation fraction=0.1, verbose=0,
                        warm start=False)
GB
accuracy: 1.0
f1 score: 1.0
precision score: 1.0
recall: 1.0
***************
In [100]:
# Метрики качества модели
metrics = metricLogger.df['metric'].unique()
metrics
Out[100]:
```

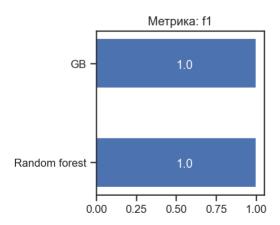
array(['precision', 'recall', 'f1', 'accuracy'], dtype=object)

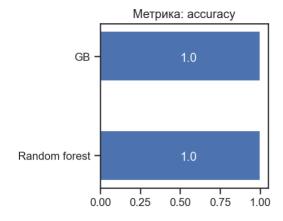
In [101]:

```
# Построим графики метрик качества модели
for metric in metrics:
    metricLogger.plot('Mетрика: ' + metric, metric, figsize=(3, 3))
```









Вывод: на основании четырех метрик из четырех используемых, модели оказались одинаково эффективно.